CONTRATO ÚNICO DE DADOS E TRATAMENTO

Projeto de Integração de Banco de Dados — VRA/ANAC | 2019, 2020 e 2021

Versão: 1.1 — atualizado em 11/11/2026 (política de exclusões aprovada pelo grupo)
Aplicação: seis pipelines (ETL e ELT de cada ano), modelagem dimensional, validação e análises
Base para elaboração: exploração e carga bruta de 2019; relatório do ETL 2019 do integrante da dupla; contrato anterior do projeto.
Regra geral: o código pode ser diferente entre ETL e ELT, mas os dados de saída, seus significados e as decisões de qualidade devem ser equivalentes.

> **Decisão central:** preservar integralmente a camada bruta; na camada analítica, **excluir as ocorrências excedentes de duplicatas exatas** e **rejeitar registros sem os atributos obrigatórios**, mantendo ambos em tabelas/relatórios de auditoria. ETL e ELT deverão aplicar as mesmas regras.

1. Objetivo e escopo

Este documento é a referência única para as duplas de **2019, 2020 e 2021**. Ele define o formato de entrada, os nomes padronizados, a política de duplicatas, os campos obrigatórios, o tratamento de nulos e datas, as medidas de atraso, o Esquema Estrela e os testes que devem passar antes de aceitar uma implementação.

Dupla	Ano	Pipeline A	Pipeline B	Revisão
1	2019	ETL 2019	ELT 2019	Cada integrante revisa o pipeline do outro
2	2020	ETL 2020	ELT 2020	Cada integrante revisa o pipeline do outro
3	2021	ETL 2021	ELT 2021	Cada integrante revisa o pipeline do outro

Não é permitido alterar individualmente unidades, nomes canônicos, regras de rejeição ou indicadores. Mudanças devem ser registradas em pull request e aprovadas pelo grupo antes de serem aplicadas aos seis pipelines.

Fluxos exigidos

- **ETL:** CSVs → extração → tratamento em Python/Pandas → carga no DW de teste ETL.
- **ELT:** CSVs → carga integral na tabela bruta PostgreSQL → tratamento em SQL → carga no DW de teste ELT.
- **Consolidação final:** após conciliar os resultados, escolher **uma** versão integrada dos anos como base analítica final. Não somar saídas ETL e ELT, pois representam as mesmas observações.

2. Entrada e preservação dos dados

1. Usar os CSVs mensais VRA da ANAC do ano atribuído à dupla. Conferir **todos os cabeçalhos** e a quantidade de arquivos; não assumir que 2020 e 2021 repetem a estrutura de 2019 sem verificar.
2. Para o padrão observado em 2019, ler com `sep=';'`, `encoding='utf-8-sig'`, `dtype=str` e `keep_default_na=False`. Validar separador/codificação nos demais anos.
3. Na **camada bruta**, manter as 20 colunas originais inicialmente em `TEXT`, incluindo campos que mais tarde serão numéricos ou datas.
4. Não aplicar `dropna()`, `drop_duplicates()`, conversão de datas ou outras regras de limpeza antes da carga bruta do **ELT**.
5. Não alterar nem sobrescrever os dados de origem. Qualquer exclusão analítica ou normalização deve ocorrer em outra camada, com registro do motivo.
6. Gerar obrigatoriamente `arquivo_origem` (`TEXT`, nome do CSV) e `linha_origem` (`INTEGER`, número sequencial do registro no arquivo, contando o cabeçalho como linha 1). No caso de campos CSV com quebras de linha internas, esse contador indica o **registro lógico**, não necessariamente a linha física do arquivo.
7. Adicionar/derivar `ano_origem` (`INTEGER`) na camada padronizada para permitir integração entre anos. `data_carga`, `pipeline` e `versao_contrato` são recomendados nos logs de execução.
8. A extração atual de 2019 tem **22 colunas** (20 originais + `arquivo_origem` e `linha_origem`). Incluir `ano_origem` como metadado adicional pode aumentar esse total; isso não altera os 20 campos originais.

3. Mapeamento canônico obrigatório — 20 colunas

O grupo usará os nomes da coluna central abaixo na **camada tratada**, independentemente dos nomes que vierem do arquivo. O identificador `numero_voo` e `codigo_di` continuam sendo texto.

Coluna original ANAC (2019)	Nome padronizado	Tipo tratado	Observação
Sigla ICAO Empresa Aérea	`companhia_icao`	`TEXT`	Código categórico
Empresa Aérea	`companhia_nome`	`TEXT`	Descrição da companhia
Número Voo	`numero_voo`	`TEXT`	Preservar zeros à esquerda
Código DI	`codigo_di`	`TEXT`	Pode ser alfanumérico
Código Tipo Linha	`tipo_linha`	`TEXT`	Não inventar significado do código
Modelo Equipamento	`modelo_equipamento`	`TEXT`	Modelo/código do equipamento
Número de Assentos	`numero_assentos`	`INTEGER NULL`	Validar antes de converter
Sigla ICAO Aeroporto Origem	`aeroporto_origem`	`TEXT`	Código ICAO
Descrição Aeroporto Origem	`descricao_origem`	`TEXT`	Descrição textual
Partida Prevista	`partida_prevista`	`TIMESTAMP NULL`	Prevista obrigatória na Fato
Partida Real	`partida_real`	`TIMESTAMP NULL`	Real opcional
Sigla ICAO Aeroporto Destino	`aeroporto_destino`	`TEXT`	Código ICAO
Descrição Aeroporto Destino	`descricao_destino`	`TEXT`	Descrição textual
Chegada Prevista	`chegada_prevista`	`TIMESTAMP NULL`	Prevista obrigatória na Fato
Chegada Real	`chegada_real`	`TIMESTAMP NULL`	Real opcional
Situação Voo	`situacao_voo`	`TEXT`	Não confundir não informado com cancelado

Coluna original ANAC (2019)	Nome padronizado	Tipo tratado	Observação
Justificativa	`justificativa`	`TEXT NULL`	Ausência permitida
Referência	`referencia`	`DATE NULL`	Formato observado em 2019; semântica a confirmar
Situação Partida	`situacao_partida`	`TEXT NULL`	Categoria da fonte
Situação Chegada	`situacao_chegada`	`TEXT NULL`	Categoria da fonte

A camada bruta mantém os **nomes originais**, ou um mapeamento documentado que permita recuperá-los sem ambiguidade. A camada tratada usa os **nomes padronizados** acima. Não mudar o nome de um campo sem atualizar o contrato.

4. Regras de padronização de valores

Tipo de campo	Regra obrigatória	Exemplo
Código ICAO, `codigo_di`, `tipo_linha`, `modelo_equipamento`	Remover espaços externos e converter para maiúsculas	`" sbkp "` → `SBKP`
`situacao_voo`, `situacao_partida`, `situacao_chegada`	Remover espaços externos e converter para maiúsculas	`" realizado "` → `REALIZADO`
Nome da companhia, descrições de aeroportos e justificativa	Remover espaços externos; **preservar a grafia/capitalização descritiva**, salvo decisão comum posterior	`" AIGLE AZUR "` → `AIGLE AZUR`
Outros textos e número do voo	Remover espaços externos; **não converter número do voo para inteiro**	`"0035"` permanece `0035`
Texto vazio ou só com espaços	Converter para `NULL` **na camada tratada**	`" "` → `NULL`
Número de assentos	Converter para inteiro apenas se for um inteiro não negativo válido; caso contrário `NULL` com registro da anomalia	`"283"` → `283`

Não remover acentos, completar automaticamente códigos, inventar descrições ou preencher horários ausentes com médias ou zeros. Se um mesmo código ICAO estiver associado a descrições distintas, gerar relatório de conflito e resolver antes de publicar uma dimensão compartilhada; não escolher arbitrariamente uma descrição.

Datas e horários

- `partida_prevista`, `partida_real`, `chegada_prevista`, `chegada_real`: ler como **`DD/MM/AAAA HH:MM`** quando esse for o formato efetivamente encontrado; converter para `TIMESTAMP` preservando data e hora.
- `referencia`: formato `AAAA-MM-DD` observado no tratamento de 2019; validar nos demais anos e converter para `DATE` somente quando a data for válida.
- Fazer verificação de **calendário e horário**, não só expressão regular. Uma data preenchida inválida deve gerar anomalia/rejeição conforme a obrigatoriedade do campo, sem normalização silenciosa.
- Preservar a data completa: partidas e chegadas podem ocorrer em dias diferentes.
- **Não converter fusos automaticamente.** A interpretação temporal/fuso dos períodos é uma pendência documental que deve ser resolvida em conjunto antes de análises que dependam disso.
- Não excluir registros apenas porque a data operacional cai fora do ano indicado pelo CSV; registrar a diferença entre `ano_origem` e o ano da partida prevista.

5. Política única de duplicatas — deduplicação com auditoria

Regra aprovada: cada dupla compara os **20 campos originais** em todos os arquivos mensais de seu ano, **sem considerar** `arquivo_origem`, `linha_origem` ou qualquer identificador técnico. A comparação inicial é exata, sobre os valores brutos tal como foram lidos; uma possível duplicidade apenas após `TRIM`/`UPPER` deve ser informada **separadamente**, sem exclusão automática adicional.

1. Identificar grupos de linhas iguais pelo conjunto completo de 20 campos.
2. Escolher uma linha representante de cada grupo por ordenação estável de `arquivo_origem` e `linha_origem` (e identificador estável de carga, se necessário).
3. **Manter apenas a primeira ocorrência na camada deduplicada/analítica**; as demais são **excedentes excluídas da camada analítica**.
4. Preservar todas as ocorrências na camada bruta. Registrar as excedentes em `vra_duplicatas_excluidas`, com ano, arquivo, linha e referência à ocorrência preservada ou a chave do grupo.
5. Registrar no `resumo_qualidade` quantos grupos se repetiram, quantos registros estavam envolvidos e quantas ocorrências excedentes foram excluídas.

Indicador em 2019	Quantidade identificada na exploração
Registros envolvidos em duplicatas	914
Grupos de registros duplicados	444
Ocorrências excedentes a excluir da camada analítica	470
Linhas após a deduplicação, antes das rejeições	982.944

As flags `duplicata_exata_flag` e `duplicata_exata_extra` **podem existir na auditoria**, mas não substituem a exclusão das excedentes no resultado analítico. Na `fato_voo`, não é necessário armazenar essas flags, pois só serão carregadas as ocorrências representantes. As 470 exclusões **não** são equivalentes aos 18 registros rejeitados por campos obrigatórios.

Cuidado com a contagem: se uma ocorrência repetida também for inválida, não subtrair a mesma linha duas vezes. Recomenda-se executar primeiro a deduplicação e **depois** verificar os campos obrigatórios sobre o conjunto deduplicado; registrar também a interseção duplicatas × inválidos na auditoria.

6. Rejeições e campos obrigatórios

Uma linha só pode entrar na **Fato principal** se os seguintes atributos tiverem valor válido após o tratamento:

- `companhia_icao`;
- `aeroporto_origem`;
- `aeroporto_destino`;
- `partida_prevista`;
- `chegada_prevista`.

Se faltar qualquer campo acima, ou alguma data prevista preenchida for inválida, enviar a linha à **tabela de rejeições**, registrando **todos** os motivos identificados. A linha deve continuar na camada bruta. Não inventar uma companhia, aeroporto ou data para forçar um relacionamento.

Campos opcionais: horários reais, justificativa, equipamento, código DI e assentos ausentes **não** provocam rejeição por si só. Não equiparar `NULL` em horário real a cancelamento. Manter `REALIZADO`, `CANCELADO` e `NÃO INFORMADO` separados, quando presentes.

A tabela de rejeições deve registrar `ano_origem`, `arquivo_origem`, `linha_origem`, motivo(s) da rejeição, campos essenciais, `numero_voo` e `situacao_voo`. Contar **linhas rejeitadas**, não motivos (uma linha pode apresentar mais de um motivo).

Nota de 2019: o ETL anterior apontou 18 linhas com datas previstas obrigatórias ausentes; 14 delas também tinham destino preenchido só com espaços. **Não somar 18 + 14**, pois os motivos se sobrepõem. Após excluir 470 excedentes, há 982.944 linhas. **Se** as 18 rejeições continuarem presentes nesse conjunto, a Fato terá **982.926** linhas. A contagem final exige medir a interseção entre duplicatas e rejeições no SQL. O total de 983.396 divulgado no ETL anterior **não é a meta desta nova versão**, pois ainda preservava as duplicatas.

7. Métricas e anomalias temporais

Calcular somente quando **ambos os timestamps correspondentes existirem**:

- `diferenca_partida_min = (partida_real - partida_prevista)` em minutos, **com sinal**;
- `diferenca_chegada_min = (chegada_real - chegada_prevista)` em minutos, **com sinal**;
- `atraso_partida_min = max(diferenca_partida_min, 0)`;
- `atraso_chegada_min = max(diferenca_chegada_min, 0)`.

Exemplo	Diferença assinada	Atraso
Saída pontual	0	0
Saída 20 min depois	+20	20
Saída 15 min antes	-15	0
Sem horário real	`NULL`	`NULL`

Adicionar `partida_atipica_flag` quando `ABS(diferenca_partida_min) > 1440` e `chegada_atipica_flag` quando `ABS(diferenca_chegada_min) > 1440` (24 horas). **Sinalizar, não truncar, corrigir ou eliminar automaticamente.** Quando não houver diferença calculável, manter a flag como `FALSE` e a métrica como `NULL` (ou documentar a alternativa de flag nula; todos os pipelines devem adotar a mesma escolha).

Para comparações, o grupo deve definir um **critério único de voo atrasado** (por exemplo, atraso positivo ou maior que 15 minutos) e usar o mesmo critério nas três análises. Não escolher limites diferentes por dupla.

8. Esquema Estrela compartilhado

Granularidade: uma **etapa de voo elegível registrada no VRA, após a exclusão das ocorrências excedentes de duplicatas exatas**. Uma linha corresponde à ocorrência representante aprovada por ano. Isso não corresponde a passageiros transportados ou necessariamente a uma viagem completa com conexões.

Tabela	Chave/atributos principais	Regra
`dim_tempo`	`id_tempo`, `data`, `ano`, `trimestre`, `mes`, `dia`, `dia_semana`	Datas distintas de **partida e chegada previstas**; um mesmo registro pode apontar para duas datas
`dim_companhia_aerea`	`id_companhia`, `companhia_icao`, `companhia_nome`	Código ICAO = chave natural; resolver conflitos de nomes
`dim_aeroporto`	`id_aeroporto`, `aeroporto_icao`, `descricao_aeroporto`	Uma dimensão usada nos papéis **origem** e **destino**
`dim_situacao_voo`	`id_situacao`, `situacao_voo`	Preservar categorias distintas
`dim_justificativa`	`id_justificativa`, `justificativa`	Chave `0` = `DESCONHECIDO` quando a justificativa estiver ausente
`dim_tipo_linha`	`id_tipo_linha`, `tipo_linha`	Sem inventar significado dos códigos

Tabela	Chave/atributos principais	Regra
`dim_equipamento`	`id_equipamento`, `modelo_equipamento`	Chave `0` = `DESCONHECIDO` quando o modelo estiver ausente
`fato_voo`	`id_voo` + FKs + atributos operacionais + métricas	Um registro por ocorrência elegível e deduplicada; manter metadados de origem

Campos mínimos sugeridos na `fato_voo`: `id_voo`, `id_companhia`, `id_aeroporto_origem`, `id_aeroporto_destino`, `id_tempo_partida`, `id_tempo_chegada`, `id_situacao`, `id_justificativa`, `id_tipo_linha`, `id_equipamento`; `numero_voo`, `codigo_di`, `referencia`, `situacao_partida`, `situacao_chegada`; quatro timestamps; `numero_assentos`, `quantidade_voos` (= 1 por ocorrência), quatro medidas de atraso/diferença, duas flags de horário atípico e metadados de rastreabilidade (flags de duplicatas permanecem na auditoria).

Usar **chaves técnicas** nas dimensões. As chaves numéricas internas não precisam coincidir entre o DW experimental ETL e o DW experimental ELT, mas os códigos naturais, atributos, quantidade de ocorrências e indicadores devem concordar. Na **base consolidada**, a mesma companhia/aeroporto deve ter o mesmo registro dimensional ao longo dos três anos. Antes da consolidação, integrar os valores distintos de **todos** os anos nas dimensões compartilhadas.

9. Saídas mínimas e nomes comuns

Cada pipeline deve publicar os seguintes resultados lógicos, ainda que a tecnologia utilizada para produzi-los seja diferente:

Camada/artefato	Nome lógico	Conteúdo
Entrada preservada	`vra_bruta` / cópia original dos CSVs	Registros intactos, metadados de proveniência
Padronização	`vra_tratada`	Dados canônicos, datas e métricas, **após deduplicação e rejeições da camada analítica**
Auditoria de duplicatas	`vra_duplicatas_excluidas`	Ocorrências excedentes excluídas da camada analítica, com proveniência
Auditoria	`vra_rejeicoes`	Ocorrências não elegíveis à Fato + motivos
Controle	`resumo_qualidade`	Contagens e regras por arquivo e ano
DW	`dim_*`, `fato_voo`	Modelo estrela definido acima

Para o **ELT**, schema sugerido: `elt_2019`, `elt_2020` ou `elt_2021`. Para o **ETL**, seguir nomes equivalentes de saída e alimentar uma área de comparação separada do ELT. A implementação final pode usar schemas `dw_etl` e `dw_elt` ou instâncias distintas, desde que não haja mistura/dobragem dos registros.

10. Validação e conciliação obrigatórias

Cada dupla deve publicar a tabela abaixo para seu ano **nos dois pipelines**. Números de 2020/2021 devem ser medidos, nunca copiados de 2019.

Indicador	Como comparar	Referência de 2019
CSVs de entrada	Arquivos esperados x arquivos encontrados	12
Colunas originais	Mapeamento de cabeçalhos	20

Indicador	Como comparar	Referência de 2019
Linhas brutas	Soma dos CSVs = `COUNT(*)` no banco	983.414
Linhas envolvidas em duplicatas exatas	`duplicata_exata_flag=TRUE`	914
Ocorrências excedentes	Linhas da auditoria de duplicatas	470
Grupos repetidos	Grupos com contagem > 1	444
Linhas rejeitadas por campos obrigatórios	Tabela de rejeições sobre deduplicados	Até 18; validar interseção
Linhas após deduplicação	Brutas menos excedentes	982.944
Linhas elegíveis para a Fato	Deduplicadas menos rejeições remanescentes	**982.926 estimadas**, sujeito à interseção
Cancelamentos da fonte	Por `situacao_voo`	18.129
Cancelamentos elegíveis	Por `situacao_voo` na Fato	18.127 no ETL
Diferenças atípicas de partida >24h	Flag após conversão	687, relatadas no ETL
Diferenças atípicas de chegada >24h	Flag após conversão	693, relatadas no ETL

Atenção às contagens: distinguir bruta, deduplicada, rejeições e Fato. A soma correta é `brutas = excedentes excluídas + rejeições remanescentes após deduplicação + linhas da Fato`. A eventual interseção com rejeições da base integral deve ser apresentada sem dupla subtração. Indicadores de atrasos da versão anterior do ETL podem mudar depois da deduplicação.

Critérios de aceite para cada PR

- ☐ Mesmos arquivos de entrada no ETL e ELT do ano; cabeçalhos validados.
- ☐ As 20 colunas originais foram mapeadas com nomes e tipos corretos.
- ☐ `arquivo_origem`, `linha_origem` e `ano_origem` disponíveis.
- ☐ Carga bruta confere com a soma dos CSVs; reexecução não duplica cargas.
- ☐ `numero_voo` mantém zeros à esquerda; `codigo_di` continua texto.
- ☐ A padronização de strings e as regras para nulos são equivalentes.
- ☐ Datas são validadas; ausências/erros obrigatórios geram rejeições auditáveis.
- ☐ Registros cancelados e situações não informadas são tratados sem confusão.
- ☐ Duplicatas excedentes são **excluídas somente da camada analítica** e arquivadas na auditoria; comparação abrange os 12 meses do ano.
- ☐ Horários atípicos são sinalizados; métricas usam minutos e distinguem `NULL` de zero.
- ☐ `dim_*` não tem chaves naturais duplicadas sem tratamento de conflitos.
- ☐ A Fato não tem chaves estrangeiras órfãs.
- ☐ ETL e ELT conciliam totais, categorias e indicadores (incluindo amostra de linhas).
- ☐ Notebook/script executa do início ao fim; resultados e autoria estão no GitHub.

11. Questões que precisam ser verificadas antes da publicação final

Este contrato resolve a **política operacional de tratamento**, mas não declara que fatos não investigados já foram confirmados:

1. **2020 e 2021:** confirmar quantidade de arquivos, nomes de colunas, mudanças de formato e categorias; documentar adaptações por ano sem mudar os nomes canônicos.
2. **Fuso e semântica da fonte:** verificar a interpretação oficial dos horários e o significado de `referencia` nos três períodos.
3. **Métrica de pontualidade:** registrar um limiar único de atraso para relatórios e gráficos. A medida em minutos já está definida; o limiar de classificação ainda depende de decisão conjunta.
4. **Conflitos interanuais:** códigos ICAO podem ter descrições diferentes entre anos; resolver com regra documentada antes de criar as dimensões finais.
5. **Qualidade real:** executar a política atualizada nos dois pipelines de 2019. As 18 rejeições e os indicadores de atrasos da implementação anterior foram medidos em cenário sem deduplicação; precisam ser recalculados na nova versão. Medir a sobreposição entre rejeições e duplicatas antes de confirmar 982.926 registros na Fato.

12. Histórico da decisão

Versão 1.1 — 11/11/2026: após alinhamento do grupo e conversa com o responsável pelo projeto de referência, substituiu-se a política anterior de apenas sinalizar duplicatas pela **exclusão controlada das 470 ocorrências excedentes (2019) na camada analítica**, preservando a fonte bruta e um registro de auditoria. Permanecem as rejeições por campos obrigatórios (18 ocorrências identificadas na fonte de 2019; contagem remanescente a confirmar após deduplicação). Os notebooks ETL e ELT e suas consultas de validação devem ser atualizados para esta versão.

13. Regra de alteração do contrato

Qualquer alteração futura deve gerar uma nova versão do arquivo (`v1.2`, `v1.3`...), com justificativa, data, autor e impacto nos três anos. Depois da aprovação, **todos os seis pipelines** devem adotar a nova regra. Não manter duas políticas diferentes sob o mesmo nome de contrato.

Local recomendado no repositório: `documentacao/contrato_unico_vra_anac.md`
Uso no relatório: seção de integração, transformações, modelagem dimensional e comparação ETL x ELT.
Fontes internas utilizadas: contrato anterior do grupo, resultados de exploração/carga bruta de 2019 e relatório do ETL 2019 apresentado pelo integrante da dupla.